

Dados do Caça-Alucinações

Como estão organizados os documentos de entrada, a base canônica `desafio1_bracis.db` e o gabarito — e como usar a base para decidir se uma citação é `real`, `inventada` ou `incompleta`.

§1 A tarefa

Encontrar as citações num documento judicial e classificar cada uma em três classes.

A entrada é um `.txt` por documento. A saída é um JSON por documento, com uma entrada por citação: o span em codepoints Unicode (`inicio` , `fim` exclusivo), o trecho literal, o tipo (`lei` ou `jurisprudencia`) e a classe. Opcionalmente, a `confianca` (0–1) de que a classe — e o link, se `real` — está correta: ela alimenta o bônus de calibração de até 10%, e quem não a envia não ganha nem perde por isso.

O alinhamento entre a predição e o gabarito é por sobreposição de spans com **IoU ≥ 0,5** — não é preciso acertar a borda exata, mas quem não entrega o span de uma citação não consegue classificá-la, e isso conta como erro de recall.

real

A citação resolve a um único **feito** da base canônica — um feito pode ter mais de um registro (ver §4). Exige `id_canonico` : acertar o rótulo sem um `doc_id` do conjunto aceito não conta.

inventada

Identificadores suficientes para buscar, mas nenhum registro correspondente existe na cobertura congelada.

incompleta

Informação insuficiente para formular a consulta, ou suficiente para buscar mas insuficiente para identificar um único feito.

§2 Os documentos de entrada

Vinte e seis peças jurídicas sintéticas, divididas em dois níveis de dificuldade — pesos 1× e 2× na nota.

Esta é a **amostra de desenvolvimento**, distribuída com gabarito para as equipes construírem e depurarem suas soluções. O conjunto final — cego — tem o mesmo formato, os mesmos níveis e distribuição de classes equivalente; ele não é distribuído: ao fim da janela, a organização executa o código submetido pelas equipes sobre esse conjunto, e é dele que sai o ranking oficial.

São petições, pareceres, decisões monocráticas e memoriais fictícios que citam acórdãos reais do acervo. Cada documento tem uma matéria coerente — cível, penal, trabalhista, eleitoral ou militar — que amarra o cabeçalho, os tribunais citados e as normas invocadas: um agravo cível não cita apelação da Justiça Militar.

A nomenclatura dos arquivos já entrega o nível: `gen_n1_001` ... `gen_n1_013` são os documentos do nível 1 e `gen_n2_001` ... `gen_n2_013` , os do nível 2. O nome do arquivo em `txt/` (sem a extensão) é o `documento_id` usado no gabarito e na submissão.

NÍVEL 1 – FORMATO PADRÃO		NÍVEL 2 – RUÍDO E VARIAÇÃO	
Peso na nota	1×		2×

Documentos	13	13
Citações	116	109
Tamanho médio	3.372 chars	3.276 chars
Classes	real 52 inventada 32 incompleta 32	real 44 inventada 32 incompleta 33
O que testa	Reconhecer a citação e resolver o doc_id na base canônica.	Normalização robusta antes de verificar: casar variantes de superfície ao mesmo identificador.

A mesma classe, escrita de dois jeitos

As citações do nível 2 apontam para registros igualmente válidos — o que muda é a superfície. Todas as amostras abaixo são **real**:

NÍVEL 1	NÍVEL 2
AREsp nº 1.996.496/RJ	AgRg no Rec.Esp. n. 1.522.200 (SC)
Recurso em Habeas Corpus nº 57.763/PR	Recurso em Habeas Corpus nº 93967 - SC
RSE nº 7000592-58.2025.7.00.0000/DF	Rec. Esp. No 1.880.529 - SP
Súmula Vinculante 10	Súmula 211 do STJ

O ruído do nível 2 combina variantes de abreviação (REsp / R.Esp. / Recurso Especial), formatação do número (1.741.784 / 1741784 / 1.741. 784), separador de UF (/PR , - PR , (PR)), confusões de OCR (0 ⇄ 0 , 1 ⇄ 1 , 5 ⇄ S , m ⇄ in) e quebras de linha no meio do identificador.

GARANTIA DO RUÍDO

Um dígito nunca é trocado por outro dígito. Isso mudaria a identidade da citação e transformaria uma **real** ruidosa numa **inventada** de fato. Todo ruído aplicado a uma citação real é recuperável por normalização — que é exatamente o que o nível 2 mede.

Distratores

Os cabeçalhos trazem números que parecem citação e não são: número dos autos em formato CNJ, protocolo, inscrição na OAB, fls. 234/567, valor da causa. Nenhum está no gabarito — extraí-los conta como falso positivo.

Atenção à distinção no formato CNJ: o número dos autos do próprio documento, no cabeçalho, é distrator; a referência a outro processo em formato CNJ, no corpo do texto, é citação (como o RSE nº 7000592-58.2025.7.00.0000/DF do quadro acima).

§3 A base canônica

Um SQLite de 93 MB com os 1.018 registros que definem o universo do desafio. É contra ele que uma citação é real ou inventada.

O banco é a **cobertura congelada**: um snapshot. Não se consulta base viva, e é isso que torna a avaliação reproduzível. Se um acórdão existe no mundo mas não está aqui, para efeito do desafio ele não existe — e, por construção, isso nunca prejudica ninguém: toda citação **real** dos documentos resolve dentro da cobertura. O caso-limite "registro real fora da cobertura" não ocorre neste dataset; se ocorresse, a citação seria excluída do scoring, não anotada como **inventada**.

COLUNA	TIPO	DESCRIÇÃO
documento_id	TEXT	Chave primária e nome do .txt. <code>doc_0201</code> para acórdãos; o próprio doc_id para súmulas e leis.
id	INTEGER	O doc_id canônico do Jusbrasil. É este número que vai em <code>resolucao.id_canonico</code> .
tribunal	TEXT	STF, STJ, TSE, TST, STM. Nulo para dispositivos de lei.
ano, relator	INT, TEXT	Só os acórdãos têm.
natureza	TEXT	acordao · sumula · dispositivo
tipo	TEXT	jurisprudencia · lei — o enum do contrato.
texto	TEXT	Inteiro teor. Idêntico a <code>txt/<documento_id>.txt</code> .
texto_len	INTEGER	Comprimento em caracteres.

`natureza` existe porque `tipo` sozinho não separa acórdão de súmula — os dois são `jurisprudencia`.

NATUREZA	REGISTROS	O QUE SÃO
<code>acordao</code>	1.000	200 por tribunal — STF, STJ, TSE, TST, STM.
<code>sumula</code>	5	Súmulas do STJ, STF e TST, incluindo vinculante.
<code>dispositivo</code>	13	Artigos de CPC, CC, CLT, CF/88, CPP, CPM, CDC, Código Eleitoral e LC 64/1990.

Há ainda uma tabela virtual `documentos_fts` (FTS5, external content) indexando o texto integral dos 1.018 registros. Ela não duplica o conteúdo — aponta para `documentos` pelo `rowid`.

§4 O gabarito

O `goldenset.csv` tem uma linha por citação esperada — 225 no total, nos 26 documentos.

É o gabarito da amostra de desenvolvimento. O gabarito do conjunto final tem o mesmo formato, permanece com a organização e é usado exclusivamente na avaliação oficial.

COLUNA	DESCRIÇÃO
--------	-----------

nível	1 ou 2 — define o peso na nota final.
documento_id, citacao_id	Identificam a citação. <code>gen_n1_004 + g3</code> — o <code>n1 / n2</code> no nome indica o nível do documento.
inicio, fim	Span em codepoints Unicode, fim exclusivo. Chave de junção com a predição.
trecho	Cópia literal de <code>texto[inicio:fim]</code> . Quebras de linha aparecem escapadas como <code>\n</code> .
tipo	<code>lei</code> ou <code>jurisprudencia</code> .
classificacao	A classe esperada. É o que se pontua.
id_canonico	Conjunto de doc_ids aceitos, separados por espaço. Só nas <code>real</code> .

`id_canonico` é um conjunto porque o mesmo número de processo pode aparecer em mais de um registro do acervo — embargos de declaração sobre o mesmo feito, por exemplo. Acertar qualquer doc_id do conjunto conta como acerto pleno.

§5 Como usar a base

O fluxo tem três passos, e a maior parte da dificuldade está no primeiro.

1 Normalizar o identificador antes de consultar

O índice FTS usa o tokenizador `unicode61`, que quebra em qualquer caractere não alfanumérico. `1.741.784` vira três tokens — `1`, `741`, `784`. A consequência prática:

```
-- funciona: a busca por frase reproduz a sequência de tokens
SELECT d.documento_id, d.id, d.tribunal
  FROM documentos_fts JOIN documentos d ON d.rowid = documentos_fts.rowid
 WHERE documentos_fts MATCH '1.741.784'; -- 1 resultado

-- não funciona: sem os separadores, é um token só, que não existe no índice
WHERE documentos_fts MATCH '1741784'; -- 0 resultados
```

Como o nível 2 entrega números sem pontuação com frequência, o pipeline precisa reconstruir a forma canônica: extrair só os dígitos e reagrupá-los de três em três a partir da direita. `"1 741 784"` como frase também casa, porque produz a mesma sequência de tokens.

Números no padrão CNJ — `0600216-46.2020.6.14.0022` — funcionam do mesmo jeito, com busca por frase.

2 Separar o registro de quem apenas o cita

Esta é a armadilha que mais custa precisão. O FTS devolve qualquer documento que mencione o número, e acórdãos citam uns aos outros o tempo todo. Uma busca por `"1.276.977"` devolve seis documentos do STF — e **nenhum deles é o RE 1.276.977**. Todos apenas o citam.

O sinal que separa os dois casos é a posição. No documento que é o processo, o número está no cabeçalho, nas primeiras dezenas de caracteres. Nos que apenas citam, ele aparece no corpo:

DOCUMENTO	POSIÇÃO	CONTEXTO
doc_0201	20	RECURSO ESPECIAL Nº 1.741.784 - PR ...
doc_0001	48	AG.REG. NA RECLAMAÇÃO 76.532 RIO DE JANEIRO ...
doc_0149	490	menção o RE 1.276.977 na ementa — apenas cita
doc_0001	957	também cita o RE 1.276.977, mais adiante

Uma abordagem mais robusta que o limiar de posição é fazer o parsing do cabeçalho: classe processual, número e UF vêm sempre nas primeiras linhas, num formato estável por tribunal. Vale construir esse índice uma vez, offline, e consultar por chave em vez de varrer o FTS a cada citação.

3 Contar os feitos e decidir a classe

Resolvida a consulta, a cardinalidade do resultado dá a classe quase diretamente — desde que se contem **feitos, não linhas**. O mesmo processo pode aparecer em mais de um registro do acervo (embargos de declaração sobre o mesmo feito, por exemplo); agrupe os candidatos por feito — número de processo normalizado + tribunal — antes de contar. É exatamente por isso que o gabarito aceita um conjunto de doc_ids.

FEITOS ENCONTRADOS	CLASSE	SAÍDA
exatamente 1 (ainda que com mais de um registro)	real	resolucao.id_canonico = a coluna id de qualquer registro do feito
0	inventada	resolucao: null
2 ou mais feitos distintos, sem critério de desempate	incompleta	resolucao: null

Uma citação sem identificadores suficientes para sequer formular a consulta — "jurisprudência pacífica desta Corte", "o dispositivo legal de regência" — é **incompleta** sem passar pelo banco. E uma referência do tipo "acórdão do STF de 2024, relatado pelo Ministro Fulano" é buscável, mas casa com dezenas de feitos distintos: também **incompleta**, por falta de critério de desempate.

```
-- a consulta por relator+ano que caracteriza a incompleta "buscável"
SELECT COUNT(*) FROM documentos
WHERE natureza = 'acordao'
  AND tribunal = 'STF' AND ano = 2024
  AND relator LIKE '%Dino%'; -- dezenas de candidatos
```

Leis e súmulas resolvem por registro próprio

Buscar "Súmula 83 do STJ" no texto dos acórdãos devolve dezenas de documentos que a mencionam — nenhum deles é a súmula. Os 18 registros de natureza **sumula** e **dispositivo** existem para isso: são o alvo da resolução, não o texto que cita.

```
-- todos os registros que não são acórdão, com o texto normativo
SELECT documento_id, id, natureza, tipo, substr(texto, 1, 80)
  FROM documentos
 WHERE natureza IN ('sumula', 'dispositivo')
 ORDER BY natureza, id;
```

Como são poucos, o caminho prático é carregá-los em memória e casar por texto normalizado do dispositivo — `art. 373, I, do CPC` e `artigo 373, inciso I, do Código de Processo Civil` apontam para o mesmo `id`.

NÃO CONFUNDA AS DUAS COLUNAS DE ID

`documento_id` é a chave interna do acervo e o nome do arquivo. `id` é o `doc_id` do Jusbrasil, e é ele que vai em `resolucao.id_canonico`. Entregar `doc_0201` onde se espera `2566535283` derruba a citação para erro, mesmo com a classe certa.

Cobertura congelada em 1.018 registros. A métrica completa e o alinhamento por IoU estão implementados no script de avaliação (`kaggle_metric.py`), distribuído junto com os dados.